TP 05 — Outils de Traitement de Texte (grep, sed et pipelines)

CO	Description	Ce TP
CO1	Understand OS fundamentals, Linux command-line environment, and operating system service interfaces	—
CO2	Understand process scheduling, memory management, and file system organization algorithms	—
CO3	Manage Linux users and permissions, implement shell scripts, and apply text processing tools	✓

Contexte

Vous êtes analyste junior dans l'équipe d'exploitation de TechConsult. Un serveur web a montré des signes de défaillance dans la matinée, et l'on vous remet l'artefact brut de l'incident : `server.log`, un journal serveur qui mélange erreurs, avertissements et simples messages d'information. Votre mission, en trois temps : **filtrer** le bruit, **transformer** le texte, puis **agréger** le tout pour répondre à la question clé — à quelle heure le serveur a-t-il le plus souffert ? Chaque objectif est piloté par un **script interactif** qui valide automatiquement votre travail et génère un rapport que vous montrez à l'enseignant.

Tableau de mission

Objectif	Mission	Script	Récompense
0	Préparer le poste de travail	— (PDF)	2 pts
1	Filtrer le bruit : rechercher et isoler les lignes utiles	`lab05_ex1.sh`	5 pts
2	Transformer le journal : normaliser et extraire	`lab05_ex2.sh`	5 pts
3	Composer des pipelines : agréger et conclure	`lab05_ex3.sh`	5 pts

Objectifs pédagogiques

À la fin de ce TP, vous serez capable de :

* Construire des expressions régulières et rechercher des motifs dans un journal
* Filtrer des lignes : compter, gérer la casse, inverser la sélection, extraire des valeurs
* Transformer du texte ligne par ligne : remplacer, supprimer, sélectionner une plage, éditer en place
* Composer un pipeline de traitement (filtrer → transformer → agréger) maillon par maillon
* Lire un résultat et conclure sur le problème posé

Pré-requis et matériel

* Terminal Bash fonctionnel (WSL2 sur Windows, Terminal.app sur macOS, ou émulateur natif Linux)
* Avoir assisté au cours CM05 (expressions régulières, recherche et transformation de texte, pipelines)
* Avoir réalisé les TP1 à TP4
* L'archive `scripts_lab05.zip` téléchargée depuis le site du cours (voir Exercice 0)
* Le fichier de données `server.log`, fourni dans l'archive (cible de tous les objectifs)

Déroulement et barème

Le TP se joue en **3 objectifs** de 25 minutes chacun. Pour chaque objectif, vous lancez le script correspondant (`./lab05_ex1.sh`, `./lab05_ex2.sh`, `./lab05_ex3.sh`) : il vous guide étape par étape, vérifie vos réponses, vous donne des indices en cas d'erreur, puis génère un **rapport** (`report_lab05_exN.txt`) que vous montrez à l'enseignant.

Pour chaque objectif, ouvrez **deux terminaux** dans le répertoire du TP : l'un pour lancer le script, l'autre pour effectuer le travail.

À la fin du TP, vous rédigerez sur papier une **synthèse libre manuscrite** (« ce que j'ai fait, pourquoi ça marche, le lien avec le cours ») — elle est notée sur 3 points.

Barème (sur 20) : Exercice 0 « Environnement prêt » (2 points) + trois objectifs notés sur 5 points chacun (15 points) + synthèse manuscrite de fin (3 points). Absence de machine opérationnelle = 0/20, quel que soit le reste.

Annexe — Aide-mémoire des commandes du TP

Ce tableau ne remplace pas le cours. En cas de doute, utilisez `man commande` *ou* `commande --help`.

Recherche : expressions régulières et grep

Commande	Syntaxe	Rôle
`grep`	`grep motif fichier`	Lignes contenant le motif
`grep -i`	`grep -i motif fichier`	Ignore la casse (majuscule/minuscule)
`grep -v`	`grep -v motif fichier`	Inverse : lignes sans le motif
`grep -c`	`grep -c motif fichier`	Compte les lignes correspondantes
`grep -n`	`grep -n motif fichier`	Affiche le numéro de ligne
`grep -E`	`grep -E 'a|b' fichier`	Regex étendues (alternance, quantificateurs)
`grep -o`	`grep -o motif fichier`	N'affiche que le fragment correspondant
`grep -w`	`grep -w mot fichier`	Mot entier (isolé du reste)
`man`	`man commande`	Page de manuel
`man -k`	`man -k mot-clé`	Recherche une commande par mot-clé
`--help`	`commande --help`	Aide rapide

Métacaractères : `.` *(un caractère quelconque),* `^` *(début de ligne),* `$` *(fin de ligne),* `[a-z]` *(classe),* `[^a]` *(négation),* `*` `+` `?` *(quantificateurs). En expressions de base (BRE),* `+` *et* `()` *doivent être échappés :* `\+`.

`man -k` *s'appuie sur la base* `whatis` *: si elle ne renvoie rien, lancez* `sudo mandb` *(Linux) ou* `sudo makewhatis` *(macOS).*

Transformation : sed

Commande	Syntaxe	Rôle
`s`	`sed 's/motif/remplacement/'`	Substitution (1re occurrence par ligne)
`g`	`sed 's/motif/remplacement/g'`	Substitution globale (toutes les occurrences)
Plage	`sed -n '5,10p'`	Affiche les lignes 5 à 10
`d`	`sed '/motif/d'`	Supprime les lignes correspondantes
`p`	`sed -n '/motif/p'`	N'affiche que les lignes correspondantes
`-i`	`sed -i 's/a/b/' fichier`	Édition en place (**irréversible !**)
Capture	`sed 's/.../\1/'`	Groupe capturé et rappelé par `\1`

Pipelines et agrégation

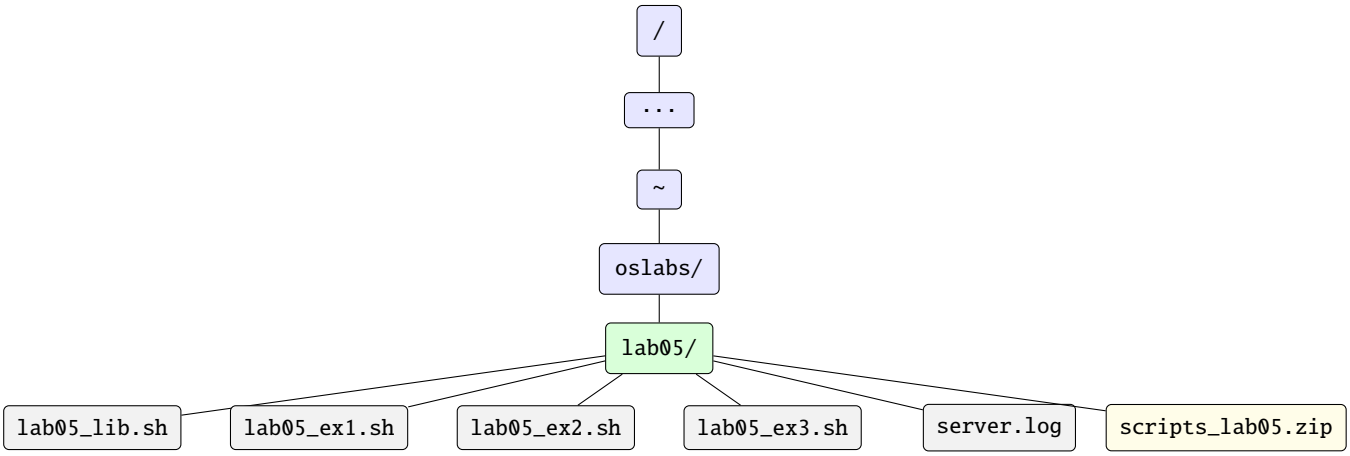
Opérateur	Syntaxe	Rôle
`|`	`cmd1 | cmd2`	stdout de cmd1 vers stdin de cmd2
`sort`	`sort [-n] [-r]`	Trie (option `-n` numérique, `-r` inverse)
`uniq`	`uniq [-c]`	Supprime les doublons adjacents (ou compte avec `-c`)
`tee`	`commande | tee fichier`	Affiche ET enregistre dans un fichier
`>`	`commande > fichier`	stdout dans un fichier (écrase)
`>>`	`commande >> fichier`	stdout en ajout
`wc`	`wc -l`	Compte les lignes reçues
`head`	`head -n N`	N premières lignes

1 Exercice 0 — Préparer le poste de travail

Durée : 15 min — 2 points « Environnement prêt »

Contexte

Avant toute mission, on prépare son poste. Ces commandes reviennent à **chaque TP** : à force de répétition, elles deviendront des réflexes. À la fin de cet exercice, votre arborescence doit ressembler à ceci :



Instructions

1. Aller à la racine : `cd /`
2. Revenir au répertoire personnel : `cd ~` ou `cd` seul
3. Entrer dans le dossier commun : `cd oslabs`
4. Créer le dossier du TP : `mkdir lab05`
5. Entrer dans le dossier du TP : `cd lab05`
6. Télécharger l'archive avec curl -(option lettre (o) en majuscule):
   `curl -O https://liaoux.github.io/it-intro-to-os/static_files/labs/lab05/scripts_lab05.zip`
7. Extraire les fichiers : `unzip scripts_lab05.zip`
8. Rendre les scripts exécutables : `chmod +x *.sh`
9. Vérifier le contenu du dossier : `ls`

Attendu : vous trouvez les 6 fichiers du schéma — `lab05_lib.sh`, `lab05_ex1.sh`, `lab05_ex2.sh`, `lab05_ex3.sh`, `server.log` et `scripts_lab05.zip`.

`curl -O` est disponible par défaut sur Linux, macOS et WSL ; il télécharge l'archive dans le dossier courant. Les outils du TP (`grep`, `sed`, `sort`, `uniq`, `tee`) sont eux aussi présents partout — aucune installation requise.

Appelez le professeur pour valider votre environnement avant de commencer les objectifs.

2 Objectif 1 — Filtrer le bruit : grep

Durée : 25 min — 5 points

Vous apprenez à isoler les lignes utiles d'un journal : rechercher un motif, compter les occurrences, tenir compte ou non de la casse, inverser la sélection, extraire des valeurs et enregistrer le résultat dans un fichier.

Lancez le script (terminal 1) : `./lab05_ex1.sh`

3 Objectif 2 — Transformer le journal : sed

Durée : 25 min — 5 points

Vous apprenez à transformer un journal : remplacer du texte, supprimer des lignes, sélectionner une plage, modifier un fichier en place et extraire une partie de chaque ligne.

Lancez le script (terminal 1) : `./lab05_ex2.sh`

4 Objectif 3 — Composer des pipelines

Durée : 25 min — 5 points

Vous assemblez les outils des deux objectifs précédents dans un enchaînement qui, maillon par maillon, transforme le journal brut en un classement lisible, puis vous concluez sur le problème de la mission.

Lancez le script (terminal 1) : `./lab05_ex3.sh`

Appelez le professeur avec vos rapports `report_lab05_exN.txt` en main, accompagnés d'une synthèse libre manuscrite (notes personnelles) : ce que vous avez fait, pourquoi ça marche, et le lien avec le cours.